

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

CMS NA ZDIEĽANIE A SPRACOVANIE
VEDECKÝCH ČLÁNKOV
DIPLOMOVÁ PRÁCA

2025

BC. SAMUEL SLÁVIK

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

CMS NA ZDIEĽANIE A SPRACOVANIE
VEDECKÝCH ČLÁNKOV
DIPLOMOVÁ PRÁCA

Študijný program: Aplikovaná informatika
Študijný odbor: Informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: RNDr. Kristína Malinovská, PhD.

Bratislava, 2025
Bc. Samuel Slávik



ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Samuel Slávik
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: CMS na zdieľanie a spracovanie vedeckých článkov
CMS for sharing and processing research papers

Anotácia: Systémy na evidovanie a zdieľanie študovanej literatúry, napr. Mendeley, sú často používané vo vedeckých skupinách a pri medzinárodnej spolupráci. Umožňujú udržiavať databázu vedeckých článkov aj s pdf originálmi, kategorizovať a tagovať články a kolaboratívne ich pridávať, združovať a zdieľať. Nevýhodou je, že články ukladajú na vzdialené úložisko a tým pádom sú spoplatnené veľkosti uložených dát a neumožňujú priamy prístup k dátam. V rámci bakalárskej práce “CMS pre kolaboratívnu správu vedeckých článkov” bol vytvorený prototyp takéhoto systému ako lokálneho doma hostovaného riešenia. Tento systém slúži ako dobrý základ pre rozšírenie jeho funkcionality, efektivity, používateľskej prístupnosti a praktickej hodnoty. Zároveň tematika spracovania textu vedeckých článkov je bohatá na možnosti využitia metód strojového učenia pre rozšírené funkcie navrhovaného systému ako napríklad rozšírené vyhľadávanie vo vedeckých článkoch, automatické hľadanie súvislostí, anotovanie a extrakcia dôležitých pojmov, generovanie súhrnov textov a podobne.

Cieľ: Cieľom diplomovej práce je rozšíriť existujúci systém na evidovanie a zdieľanie vedeckých článkov, ktorý bol vyvinutý ako bakalárska práca o rozšírenú funkcionality a nástroje na báze strojového učenia. Vylepšenie bude obsahovať dôsledné otestovanie systému pre účely doladenia používateľskej priateľskosti a dizajnu aplikácie, implementácia angličtiny ako druhého jazyka alebo prepínania jazykov. Z hľadiska používateľov a ich spätnej väzby rozšírenie možností skupinovej spolupráce s anotáciami a diskusiami. V rámci vylepšenia existujúceho softvéru preskúmať možnosti implementácie full text vyhľadávania. Ďalším cieľom práce je navrhnúť a implementovať nové nástroje pre komplexnú správu vedeckých článkov vrátane kategorizácie, anotácie, odporúčaní a vyhľadávania s využitím moderných metód strojového učenia, ako sú napríklad umelé neurónové siete. Pre implementáciu týchto funkcií tiež preskúmať a porovnať možnosti strojového učenia a vybrať najvhodnejšie metódy.

Literatúra: [1] Django: the web framework for perfectionists with deadlines <https://www.djangoproject.com/>
[2] Liu, Y. and Zhang, M., 2018. Neural network methods for natural language processing.



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

[3] Lynch, P.J. and Horton, S., 2016. Web style guide: Foundations of user experience design. Yale University Press.

Vedúci: RNDr. Kristína Malinovská, PhD.

Katedra: FMFI.KAI - Katedra aplikovanej informatiky

Vedúci katedry: doc. RNDr. Tatiana Jajcayová, PhD.

Dátum zadania: 08.12.2024

Dátum schválenia: 09.12.2024

prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu

.....
študent

.....
vedúci práce

Pod'akovanie:

Abstrakt

Názov práce:	CMS na zdieľanie a spracovanie vedeckých článkov
Univerzita:	Univerzita Komenského v Bratislave
Fakulta:	Fakulta matematiky, fyziky a informatiky
Pracovisko:	Katedra aplikovanej informatiky
Študijný program:	Aplikovaná informatika
Autor:	Bc. Samuel Slávik
Vedúci práce:	RNDr. Kristína Malinovská, Phd.
Dátum odovzdania:	

Táto diplomová práca sa zaoberá návrhom a implementáciou systému na evidovanie a zdieľanie vedeckých článkov, ktorý využíva metódy strojového učenia na zlepšenie správy vedeckej literatúry v akademických a výskumných prostrediach. Cieľom práce je rozšíriť existujúci prototyp, ktorý bol vytvorený v rámci bakalárskej práce, o nové funkcionality, ako sú automatické vyhľadávanie v plnom texte, extrakcia kľúčových slov a sumarizácia textov. Systém taktiež zahŕňa možnosti skupinovej spolupráce prostredníctvom anotácií a diskusií, čím podporuje kolaboráciu medzi používateľmi a zdieľanie vedomostí. Implementácia systému využíva moderné metódy strojového učenia, konkrétne neurónové siete, na analýzu a spracovanie vedeckých textov, čo umožňuje zlepšiť efektívnosť vyhľadávania a kategorizácie článkov. Práca ďalej skúma rôzne prístupy k strojovému učeniu a vyhodnocuje ich účinnosť pri extrakcii dôležitých informácií zo študovaných článkov. Testovanie a porovnanie výsledkov rôznych modelov strojového učenia pomáha identifikovať najvhodnejšie metódy pre aplikáciu na spracovanie vedeckých textov. Konečným výsledkom práce je systém, ktorý poskytuje flexibilné a efektívne riešenie pre organizáciu, spravovanie a zdieľanie vedeckých článkov v prostredí, ktoré podporuje nielen individuálny výskum, ale aj spoluprácu a kolektívne zdieľanie poznatkov.

Kľúčové slová: machine learning, neural net, semantic tagging, natural language processing, keywords extraxtion

Abstract

Thesis title:	CMS for sharing and processing scientific articles
University:	Comenius University Bratislava
Faculty:	Faculty of Mathematics, Physics and Informatics
Department:	Department of Applied Informatics
Degree course:	Applied Informatics
Author:	Bc. Samuel Slávik
Supervisor:	RNDr. Kristína Malinovská, Phd.
Submission date::	

This thesis deals with the design and implementation of a system for registering and sharing scholarly articles that uses machine learning methods to improve the management of scholarly literature in academic and research environments. The aim of the work is to extend the existing prototype, which was developed as part of the bachelor thesis, with new functionalities such as automatic full-text search, keyword extraction and text summarization. The system also includes group collaboration capabilities through annotations and discussions, thus promoting collaboration between users and knowledge sharing. The system implementation uses modern machine learning methods, specifically neural networks, to analyse and process scientific texts, allowing for improved efficiency in searching and categorising articles. The thesis further explores different machine learning approaches and evaluates their effectiveness in extracting relevant information from the articles under study. Testing and comparing the results of different machine learning models helps to identify the most appropriate methods for application to scientific text processing. The end result of the work is a system that provides a flexible and efficient solution for organizing, managing, and sharing scholarly articles in an environment that supports not only individual research, but also collaboration and collective knowledge sharing.

Keywords: machine learning, neural net, semantic tagging, natural language processing, keywords extraxtion

Obsah

Zoznam použitých skratiek	1
Úvod	3
1 Východiská práce	5
1.1 Význam vedeckej literatúry a jej správy	5
1.2 Existujúce systémy a ich obmedzenia	6
1.3 Ciele a prínosy práce	8
2 Technologické východiská systému	9
2.1 Technologické východiská systémov pre správu odborných dokumentov	9
2.2 Reprezentácia textu v informačných a odporúčacích systémoch	10
2.3 Metóda TF-IDF a klasické prístupy k reprezentácii textu	11
2.4 Kosínová podobnosť a porovnávanie dokumentov	12
2.5 Embeddingy a moderné NLP prístupy	14
2.6 Obsahové odporúčanie vedeckých článkov	15
2.7 Spracovanie PDF a význam metadát	16
3 Analýza východiskového systému a požiadavky na rozšírenie	19
3.1 Východiskový stav systému	19
3.1.1 Identifikované obmedzenia pôvodného riešenia	20
3.2 Požiadavky na rozšírenie systému	20
3.2.1 Use cases	20
3.2.2 Funkčné požiadavky	23
3.2.3 Nefunkčné požiadavky	23
4 Návrh systému	25
4.1 Celkový návrh architektúry systému	25
4.2 Návrh dátového a databázového modelu	25
4.3 Návrh funkcie „Similar to this article“	25
4.4 Návrh funkcie „Recommended for you“	25

5	Implementácia rozšíreného systému	27
5.1	Modernizácia frontendovej vrstvy	27
5.2	Implementácia textových reprezentácií článkov	27
5.3	Implementácia funkcie „Similar to this article“	27
5.4	Implementácia funkcie „Recommended for you“	27
5.5	Implementácia spracovania spätnej väzby	27
6	Experimentálne vyhodnotenie	29
6.1	Cieľ experimentu a výskumná otázka	29
6.2	Dataset a príprava dát	30
6.3	Metodika hodnotenia	31
6.4	Experiment 1 – Vyhodnotenie funkcie „Recommended for you“	33
6.4.1	Základný experiment personalizovaných odporúčaní	33
6.4.2	Rozšírený experiment personalizovaných odporúčaní	37
6.5	Porovnanie výsledkov a interpretácia	41
6.6	Zhrnutie experimentálnej časti	42
7	Diskusia a zhodnotenie	45
	Záver	47
	Príloha A	53

Zoznam použitých skratiek

Úvod

Kapitola 1

Východiská práce

1.1 Význam vedeckej literatúry a jej správy

Vedecká literatúra predstavuje jeden zo základných pilierov zaznamenávania, overovania a šírenia podložených informácií. Odborné články, konferenčné príspevky, monografie a ďalšie vedecké výstupy predstavujú prostriedok, prostredníctvom ktorého sa zaznamenávajú a šíria výsledky výskumu, metodické postupy a teoretické poznatky dôležité pre ďalší rozvoj jednotlivých vedných oblastí. V súčasnej digitálnej spoločnosti sa však podmienky vedeckej komunikácie odlišujú od spôsobu šírenia vedeckej literatúry v minulosti. Vedecká komunikácia už neprebíha iba prostredníctvom tradičných publikačných kanálov, ale je úzko prepojená s online informačnou infraštruktúrou, digitálnymi repozitármi, databázami a vyhľadávacími nástrojmi [1].

Význam správy vedeckej literatúry rastie aj v súvislosti s dlhodobým rastom objemu vedeckých publikácií. Bibliometrická analýza ukazuje, že moderná veda rastie dlhodobo vysokým tempom a počet publikácií sa v čase výrazne zvyšuje. Podobne ako v iných oblastiach digitálneho informačného prostredia sa aj pri vedeckej literatúre používateľ dnes dokáže relatívne ľahko dostať k veľkému množstvu dokumentov. Problémom však často nie je samotný prístup k informáciám, ale identifikácia tých zdrojov, ktoré sú pre jeho potreby skutočne najrelevantnejšie. Rast vedeckej produkcie preto zvyšuje význam systémov, ktoré dokážu odborné články nielen ukladať, ale aj efektívne organizovať, vyhľadávať, triediť a odporúčať [2].

Z pohľadu používateľa už nestačí, aby bol článok iba publikovaný a formálne dostupný. Rovnako dôležité je, aby bol jednoducho objaviteľný v databázach, akademických vyhľadávačoch a interných informačných systémoch. V tejto súvislosti je potrebné venovať pozornosť tomu, ako sú vedecké práce indexované a zobrazované vo výsledkoch vyhľadávania. Dôležitú úlohu pri tom zohrávajú jasne definované a kvalitne vyplnené metadáta článku. Vyššie umiestnené dokumenty majú väčšiu pravdepodobnosť, že budú čítané, pričom akademické vyhľadávače často pracujú s rôzne váženými dokumentovými

poľami. Osobitný význam tak môžu mať názov, abstrakt, autori či kľúčové slová [3].

V súčasnosti sa vedecké články vyhľadávajú viacerými spôsobmi. Používatelia najčastejšie využívajú akademické vyhľadávače, bibliografické a citačné databázy, digitálne knižnice, repozitáre vedeckých inštitúcií a vydavateľské platformy. Tento vývoj ukazuje, že vyhľadávanie vedeckej literatúry už nie je obmedzené len na jednoduché textové dopyty, ale zahŕňa aj prácu s metadátami, citačnými vzťahmi a personalizovaným objavovaním relevantného obsahu [3, 4].

Správa vedeckej literatúry tak nepredstavuje iba evidenciu dokumentov, ale zahŕňa aj kvalitné spracovanie metadát, podporu inteligentného vyhľadávania, možnosť tematickej organizácie, filtrovania a v modernejších systémoch aj prvky personalizácie [3]. Ak má používateľ pracovať efektívne, systém mu musí pomôcť nielen nájsť konkrétny článok, ale aj orientovať sa v súvisiacom obsahu, rozpoznať tematicky príbuzné dokumenty a priebežne odhaľovať relevantné nové zdroje. Takéto požiadavky sú mimoriadne dôležité najmä pri práci s vedeckými článkami, kde sa často kombinuje cieľové vyhľadávanie s priebežným sledovaním vývoja v danej oblasti [1].

S významom objaviteľnosti článku úzko súvisí aj kvalita textových a bibliografických údajov, ktoré článok sprevádzajú. S neustálym nárastom počtu vedeckých článkov je zvýšenie objaviteľnosti vedeckých článkov v databázach a vyhľadávačoch zásadné. Dôležitú úlohu pritom zohráva aj používanie kľúčových termínov v názve, abstrakte a sekcii kľúčových slov, čo môže zlepšiť indexovanie aj objaviteľnosť článku. To potvrdzuje dôležitý informačný základ pre vyhľadávanie, triedenie a ďalšie spracovanie odborných dokumentov [5].

Na základe uvedeného možno konštatovať, že správa vedeckej literatúry je dnes neoddeliteľnou súčasťou efektívnej vedeckej práce. V prostredí neustále rastúceho objemu publikácií už nestačí vytvoriť úložisko dokumentov, potrebné je budovať systémy, ktoré podporujú vyhľadávanie, organizáciu, interpretáciu a personalizované prístupňovanie obsahu [2, 1]. Tieto potreby tvoria základ pre návrh moderných systémov na správu odborných článkov, ktoré kombinujú prácu s metadátami, textovou reprezentáciou obsahu a odporúčovacími mechanizmami [3].

1.2 Existujúce systémy a ich obmedzenia

V súčasnosti existuje viacero platforiem a nástrojov, ktoré podporujú prácu s vedeckou literatúrou. Patria medzi ne akademické vyhľadávače, citačné databázy, digitálne knižnice, inštitucionálne a odborové repozitáre, ako aj špecializované služby zamerané na objavovanie súvisiacich vedeckých zdrojov. Tieto systémy umožňujú používateľom vyhľadávať odborné články, pracovať s metadátami dokumentov, sledovať citačné väzby a v niektorých prípadoch aj objavovať tematicky príbuzný obsah. Ich rozvoj odráža

potrebu efektívnej orientácie v rastúcom priestore vedeckých publikácií, kde už nestačí iba jednoduché fulltextové vyhľadávanie [6, 3].

Jedným z najznámejších nástrojov je Google Scholar, ktorý je využívaný najmä pre svoju jednoduchosť a široké pokrytie rôznych typov vedeckých dokumentov. Rankin-gový algoritmus tohto systému však nie je transparentný, významnú úlohu pri radení výsledkov zohráva citačný ohlas článkov [4]. Výskyt hľadaného termínu v názve článku navyše môže mať väčší vplyv na pozíciu vo výsledkoch než samotná frekvencia výrazu v plnom texte [4]. To znamená, že aj keď Google Scholar predstavuje silný nástroj na akademické vyhľadávanie, jeho výsledky nemožno považovať za úplne neutrálne a rovnako vhodné pre všetky typy informačných potrieb.

Modernejší prístup reprezentuje napríklad Semantic Scholar. Tento systém je opísaný ako riešenie založené na rozsiahlej literature graph štruktúre, ktorá prepája články, autorov, entity a citačné vzťahy. Takýto prístup umožňuje pokročilejšie spracovanie vedeckej literatúry a bohatšie formy objavovania súvisiacich dokumentov [6]. Na druhej strane však predpokladá robustnú infraštruktúru, rozsiahle dátové spracovanie a vysokú mieru automatizácie, čo môže byť nevýhodné pri menších alebo interných systémoch.

Dôležitú úlohu zohrávajú aj ďalšie akademické vyhľadávače, databázy a repozitáre, ktoré sa odlišujú spôsobom indexácie a prácou s dokumentovými poľami. Nie všetky systémy pritom indexujú plný text dokumentov, niektoré pracujú najmä s názvom, abstraktom, autormi alebo kľúčovými slovami. Úspešnosť vyhľadania preto nezávisí iba od samotného obsahu článku, ale aj od kvality metadát a spôsobu, akým je dokument spracovaný vo vyhľadávacom systéme [3]. Obmedzením týchto riešení môže byť aj neúplná indexácia obsahu alebo závislosť od uzavretých publikačných databáz.

Popri vyhľadávacích nástrojoch existujú aj riešenia zamerané priamo na odporúčanie vedeckých článkov. Medzi takéto prístupy patria aj modely, ktoré kombinujú obsahovú analýzu dokumentov s informáciami z citačnej siete s cieľom zlepšiť relevanciu odporúčaného obsahu [7]. Takéto systémy ukazujú posun od jednoduchého vyhľadávania k inteligentnejšiemu a personalizovanejšiemu vyhľadávaniu vedeckých zdrojov. Ich nevýhodou však býva vyššia implementačná náročnosť, potreba rozsiahlych externých dát a obmedzená použiteľnosť v prostredí menších komunit používateľov.

Z uvedeného prehľadu vyplýva, že existujúce systémy ponúkajú viacero dôležitých funkcií, ako sú vyhľadávanie, indexácia, práca s metadátami, citačné prepojenia a odporúčanie súvisiaceho obsahu. Ich obmedzenia sa však prejavujú najmä v rozdielnej kvalite indexácie, závislosti od externých dátových zdrojov a v obmedzenej podpore personalizácie alebo komunitnej práce v menších skupinách [3, 7]. Tieto nedostatky vytvárajú priestor pre návrh vlastného systému, ktorý bude spájať správu odborných článkov s odporúčovacími mechanizmami a so zohľadnením používateľskej aj skupinovej interakcie.

1.3 Ciele a prínosy práce

Diplomová práca je zameraná na rozšírenie existujúceho systému pre správu vedeckých článkov o nové funkcionality, ktoré zvýšia jeho využiteľnosť pri práci s odbornou literatúrou. Vychádza z predpokladu, že v prostredí rastúceho objemu vedeckých informácií je potrebné nielen ukladať a spravovať odborné články, ale aj efektívne podporovať ich vyhľadávanie, organizáciu a objavovanie relevantného obsahu.

Práca nadväzuje na už existujúci prototyp webového systému určeného na správu a zdieľanie vedeckých článkov. Pôvodné riešenie poskytovalo základné funkcie pre evidenciu článkov, prácu so skupinami a vybrané možnosti správy obsahu, no neobsahovalo pokročilejšie odporúčacie mechanizmy ani modernizované používateľské rozhranie. Dôvodom rozšírenia systému bola potreba zvýšiť jeho praktickú hodnotu pre používateľa a zároveň vytvoriť priestor na experimentálne overenie vybraných prístupov k odporúčaniam odborných článkov.

Hlavným cieľom diplomovej práce je navrhnuť, implementovať a experimentálne vyhodnotiť rozšírenie systému pre správu vedeckých článkov o funkcionality založené na obsahovom odporúčaní. Dôraz sa kladie najmä na implementáciu funkcie odporúčania podobných článkov a personalizovaného odporúčania pre používateľa, pričom systém využíva dve metódy reprezentácie textu, a to TF-IDF a embeddingy založené na modeli Sentence-BERT.

Konkrétne to zahŕňalo modernizáciu frontendovej vrstvy, rozšírenie databázového modelu o údaje potrebné pre odporúčanie, implementáciu mechanizmu tvorby textových reprezentácií článkov, návrh a realizáciu odporúčacích funkcií, spracovanie používateľskej spätnej väzby a prípravu experimentálneho vyhodnotenia oboch metód.

Práca prepája oblasť správy odborných dokumentov, informačných systémov a odporúčacích mechanizmov. Výsledkom je implementované riešenie, ktoré umožňuje porovnať tradičný prístup TF-IDF s modernejším embeddingovým prístupom a na základe experimentálneho vyhodnotenia určiť, ktorý z nich je pre daný typ systému vhodnejší.

Kapitola 2

Technologické východiská systému

2.1 Technologické východiská systémov pre správu odborných dokumentov

Základným princípom fungovania webového systému je architektúra klient - server. Na jednej strane vystupuje klient, spravidla webový prehliadač alebo iná aplikácia používateľa, na druhej strane server ktorý spracúva požiadavky a poskytuje odpovede vo forme dát alebo prezentačného obsahu. Komunikácia medzi klientom a serverom prebieha prostredníctvom protokolu HTTP, pričom klient posiela požiadavku na konkrétny zdroj a server na ňu reaguje odoslaním príslušnej odpovede. Takýto model tvorí základ väčšiny súčasných webových aplikácií, pretože umožňuje prirodzené oddelenie používateľského rozhrania od aplikačnej logiky a dátového spracovania [8].

V prostredí systémov pre správu odborných dokumentov zohráva kľúčovú úlohu backendová vrstva. Ide o časť systému, ktorá spracúva požiadavky od klienta, zabezpečuje aplikačnú logiku a komunikuje s databázou. Do tejto vrstvy patrí napríklad overovanie používateľov, spracovanie formulárov, riadenie prístupu k dokumentom, práca s metadátami, vyhľadávacie operácie alebo vykonávanie odporúčacích mechanizmov. Kvalitne navrhnutá backendová vrstva pritom priamo ovplyvňuje udržateľnosť a rozšíriteľnosť celého systému [9].

Frontendová vrstva predstavuje časť systému, s ktorou používateľ vstupuje do priameho kontaktu. Jej úlohou je sprostredkovať funkčnosť systému zrozumiteľným a používateľsky prístupným spôsobom. Vo webových systémoch ide najmä o zobrazovanie údajov, navigáciu medzi jednotlivými časťami aplikácie, zadávanie vstupov a odosielanie požiadaviek na server. Práve kvalita frontendu rozhoduje o tom, ako prirodzene dokáže používateľ vyhľadávať dokumenty, pracovať s ich detailmi alebo využívať pokročilejšie funkcie. Hoci frontendová vrstva spravidla neobsahuje jadro aplikačnej logiky, predstavuje rozhodujúce rozhranie medzi používateľom a technologickým jadrom celej aplikácie [10].

Neoddeliteľnou súčasťou webového systému je databázová vrstva, ktorá zabezpečuje trvalé uloženie dát, ich organizáciu a efektívne sprístupnenie ostatným častiam systému. V prípade systémov pre správu odborných dokumentov databáza spravidla uchováva informácie o článkoch, používateľoch, autoroch, kategóriách, kľúčových slovách, metadátach a rôznych formách interakcie používateľa so systémom. Bez spoľahlivo navrhnutej databázovej vrstvy by nebolo možné tieto údaje konzistentne spravovať ani efektívne využívať v ďalších častiach aplikácie [11].

S databázovou vrstvou úzko súvisí dátový model, je to abstraktný opis toho, aké typy údajov systém spracúva, aké vzťahy medzi nimi existujú a akým spôsobom budú tieto údaje organizované. Jeho úlohou nie je iba technicky pripraviť štruktúru databázy, ale aj zachytiť logiku domény, ktorú systém podporuje. Kvalitne navrhnutý dátový model znižuje riziko redundancie, podporuje konzistenciu údajov a vytvára základ pre ďalší rozvoj systému. Pri systémoch na správu odborných dokumentov to znamená dôkladne premyslieť vzťahy medzi článkami, používateľmi, metadátami a ďalšími entitami, ktoré do správy obsahu vstupujú [12].

Klientská časť, serverová logika a databázová vrstva spolu tvoria funkčný celok, ktorého kvalita závisí od toho, ako dobre sú navrhnuté ich vzájomné väzby a komunikácia, pričom dôležitú úlohu pritom zohráva aj kvalitne navrhnutý dátový model. [9].

2.2 Reprezentácia textu v informačných a odporúčacích systémoch

Text predstavuje základný nositeľ informácie v mnohých informačných systémoch, no z pohľadu počítačového spracovania ide o neštruktúrovaný údaj, s ktorým nemožno priamo vykonávať porovnávanie, vyhľadávanie ani ďalšie analytické operácie. Aby systém mohol s dokumentmi pracovať algoritmicky, je potrebné previesť ich obsah do takej podoby, ktorú možno strojovo spracovať. Textová reprezentácia je teda základným predpokladom pre indexovanie, porovnávanie, triedenie aj odporúčanie obsahu [13].

Prirodzený jazyk obsahuje veľké množstvo slov, výrazov a významových vzťahov, ktoré sú pre človeka zrozumiteľné, no pre počítač musia byť vyjadrené formálne. V informačných systémoch sa preto dokument spravidla transformuje na súbor vlastností, ktoré zachytávajú jeho obsah vo forme vhodnej na ďalšie výpočty. Takáto reprezentácia umožňuje identifikovať podobnosť medzi dokumentmi, merať relevanciu vo vzťahu k dopytu používateľa a pracovať s textom ako s dátovým objektom, nad ktorým možno realizovať ďalšie operácie [13].

Pri porovnávaní dokumentov nestačí sledovať iba výskyt jednotlivých slov, dôležité je aj to, aké charakteristiky dokumentu sú pri reprezentácii zachytené. V praxi

môže byť textová reprezentácia založená na názve dokumentu, abstrakte, kľúčových slovách ale aj kategóriách alebo ďalších metadátach, ktoré spolu vytvárajú obsahový opis dokumentu. Čím vhodnejšie je tento opis navrhnutý, tým presnejšie môže systém pracovať s porovnávaním a odporúčaním obsahu [13, 5].

Tradičným prístupom k reprezentácii textu je chápanie dokumentu ako množiny termínov, ktorým sú priradené váhy podľa ich významu v rámci konkrétneho dokumentu aj celej kolekcie. Takáto reprezentácia vytvára základ pre vektorový model dokumentu, v ktorom možno text previesť do číselného priestoru a následne s ním pracovať matematickými metódami. Kvalita reprezentácie vstupných dát pritom významne ovplyvňuje aj kvalitu nadväzujúcich analytických alebo odporúčacích procesov [13].

Textová reprezentácia vytvára spojenie medzi obsahom dokumentu a výpočtovými mechanizmami systému. Bez vhodnej reprezentácie by systém nevedel určiť, ktoré dokumenty sú si navzájom podobné, ktoré z nich sú relevantné pre konkrétneho používateľa alebo aké tematické vzťahy medzi nimi existujú. Reprezentácia textu tak netvorí iba technický predspracovateľský krok, ale predstavuje jeden zo základných stavebných prvkov informačných a odporúčacích systémov. Pri systémoch pracujúcich s odbornými dokumentmi je jej význam ešte výraznejší, pretože práve kvalita textového opisu článku rozhoduje o tom, ako spoľahlivo bude možné vyhľadávať súvisiace dokumenty a generovať obsahovo relevantné odporúčania [13].

2.3 Metóda TF-IDF a klasické prístupy k reprezentácii textu

Jedným z najvýznamnejších klasických prístupov k reprezentácii textu je metóda TF-IDF, ktorá patrí medzi základné techniky informačného vyhľadávania a spracovania textových dokumentov. Jej význam spočíva v tom, že umožňuje previesť text dokumentu na číselnú reprezentáciu založenú na váhovaní jednotlivých termínov podľa ich dôležitosti. V klasických textových modeloch sa dokument často chápe ako množina slov alebo termínov, pričom nie všetky majú rovnakú vypovedaciu hodnotu. Práve metódy váhovania termínov sa snažia rozlíšiť, ktoré slová sú pre obsah dokumentu informatívne a ktoré sa vyskytujú príliš všeobecne na to, aby mali výraznú rozlišovaciu schopnosť [14, 13].

Základný princíp TF-IDF vychádza zo spojenia dvoch zložiek. Prvou je *term frequency* (TF), teda frekvencia termínu v konkrétnom dokumente. Tá vyjadruje, ako často sa dané slovo v dokumente vyskytuje, pričom vyššia frekvencia spravidla naznačuje väčší význam termínu pre obsah daného textu. Druhou zložkou je *inverse document frequency* (IDF), ktorá zohľadňuje, v koľkých dokumentoch celej kolekcie sa termín objavuje. Ak sa určitý výraz vyskytuje vo veľkom množstve dokumentov, jeho schopnosť

odlišovať dokumenty od seba je nízka; naopak, termín prítomný len v menšom počte dokumentov má vyššiu rozlišovaciu hodnotu [13, 14].

Význam frekvencie termínov a ich rozlišovacej schopnosti je v informačných systémoch zásadný. Slová, ktoré sa v dokumente objavujú často, môžu signalizovať jeho hlavnú tému, no samy osebe nestačia na kvalitnú reprezentáciu obsahu. Ak by systém pracoval iba s prostou frekvenciou slov, zvýhodňoval by aj veľmi všeobecné výrazy, ktoré sa vyskytujú naprieč veľkým množstvom dokumentov. Kombinácia lokálnej dôležitosti termínu v dokumente a jeho globálnej informatívnosti v rámci celej kolekcie umožňuje vytvoriť reprezentáciu, ktorá je vhodnejšia na porovnávanie dokumentov a vyhľadávanie relevantného obsahu. Výskum v oblasti automatického váhovania termínov dlhodobo ukazuje, že vhodne zvolené schémy váhovania patria k rozhodujúcim faktorom úspešnosti textového vyhľadávania [14].

Metóda TF-IDF je osobitne vhodná pri práci s odbornými textami, pretože tieto dokumenty často obsahujú tematicky špecifické termíny, ktorých výskyt dokáže dobre signalizovať obsahové zameranie článku. Vedecké texty pritom zvyčajne pracujú s relatívne ustálenou terminológiou, čo umožňuje efektívne zachytiť ich tematický profil prostredníctvom váhovaných termínov. Ak sa do reprezentácie zahrnú názov, abstrakt, kľúčové slová alebo ďalšie metadáta článku, TF-IDF poskytuje praktický spôsob, ako získať porovnateľné vektorové reprezentácie dokumentov bez potreby zložitejších jazykových modelov [13].

Napriek svojej jednoduchosti ostáva TF-IDF dôležitým východiskom aj v súčasných informačných a odporúčacích systémoch. Jeho výhodou je zrozumiteľnosť, relatívne nízka výpočtová náročnosť a schopnosť dobre pracovať s kolekciami dokumentov, v ktorých zohráva dôležitú úlohu presná terminológia. Zároveň však ide o prístup založený na povrchovej textovej reprezentácii, ktorý nepracuje priamo so sémantickým významom slov a viet. V modernejších systémoch sa preto bežne porovnáva s embeddingovými prístupmi, ktoré sa snažia zachytiť aj významové vzťahy medzi textovými jednotkami [13].

2.4 Kosínová podobnosť a porovnávanie dokumentov

V odporúčacích aj informačných systémoch zohráva miera podobnosti dôležitú úlohu pri rozhodovaní o tom, ktoré objekty sú si navzájom obsahovo blízke. Ak sú dokumenty reprezentované vo forme vektorov, systém potrebuje určiť, do akej miery sa tieto vektory približujú, a teda nakoľko sa približuje aj ich obsah. Výpočet podobnosti preto patrí medzi základné operácie pri vyhľadávaní, zoradovaní a odporúčaní dokumentov. Jedná sa o mechanizmus, ktorý priamo prepája reprezentáciu dokumentu s rozhodovaním systému o relevancii [13].

Jednou z najpoužívanějších mier podobnosti vo vektorovom modeli je kosínová podobnosť. Jej princíp spočíva v porovnávaní uhla medzi dvoma vektormi, pričom sa nesleduje ich absolútna veľkosť, ale smer vektorov v priestore. Ak dva vektory smerujú podobným smerom, možno predpokladať, že reprezentujú obsahovo podobné dokumenty. Naopak, ak je medzi nimi veľký uhol, ich obsahová príbuznosť je nižšia. Výhodou tejto miery je, že pri porovnávaní textových reprezentácií zohľadňuje rozloženie váh jednotlivých prvkov bez toho, aby bola neprimerane ovplyvnená samotnou dĺžkou dokumentu [13].

Kosínová podobnosť dvoch vektorov A a B sa štandardne vyjadruje vzťahom:

$$\cos_sim(A, B) = \frac{A \cdot B}{\|A\| \|B\|} \quad (2.1)$$

kde $A \cdot B$ predstavuje skalárny súčin vektorov a $\|A\|$, $\|B\|$ označujú ich normy. Výsledná hodnota vyjadruje mieru podobnosti medzi dvoma reprezentáciami. Pri bežných textových reprezentáciach založených na nezáporných váhach sa často hodnota pohybuje v intervale od 0 do 1, pričom vyššia hodnota znamená väčšiu podobnosť dokumentov alebo textových jednotiek [13].

Pri porovnávaní typu dokument-dokument sa kosínová podobnosť využíva na určenie miery obsahovej blízkosti medzi textovými reprezentáciami jednotlivých dokumentov. Ak sú dokumenty vyjadrené vo forme vektorov, možno na základe tejto miery určiť, ktoré z nich sú si navzájom tematicky najbližšie. Výsledkom je skóre podobnosti, podľa ktorého možno dokumenty zoradiť a identifikovať obsahovo príbuzné texty [13].

Podobný princíp sa uplatňuje aj v odporúčacích systémoch, kde sa kosínová podobnosť používa na porovnávanie textových reprezentácií obsahu s cieľom určiť relevanciu dokumentov vzhľadom na zvolený referenčný základ. Môže ísť napríklad o porovnávanie medzi dokumentmi navzájom alebo o porovnávanie dokumentov s reprezentáciou používateľských preferencií. Kosínová podobnosť tak predstavuje univerzálny nástroj na prepájanie textovej reprezentácie s úlohami vyhľadávania, filtrovania a odporúčania obsahu [13].

Význam kosínovej podobnosti sa zachováva aj v modernejších NLP prístupoch. Pri embeddingových modeloch už jednotlivé rozmery vektora nepredstavujú iba explicitné váhy termínov, ale nesú aj významové informácie o texte. Aj v tomto prostredí však zostáva cosine similarity jednou z najpraktickejších mier na určovanie blízkosti textových reprezentácií. V prípade modelu Sentence-BERT je priamo zdôraznené, že vytvorené vetné embeddingy sú navrhnuté tak, aby sa dali efektívne porovnávať pomocou cosine similarity pri úlohách sémantickej podobnosti a vyhľadávania najbližších textových jednotiek [15]. To ukazuje, že kosínová podobnosť tvorí dôležitý most medzi klasickým vektorovým modelom a modernými embeddingovými prístupmi.

2.5 Embeddingy a moderné NLP prístupy

V modernej oblasti spracovania prirodzeného jazyka predstavujú embeddingy spôsob, ako previesť jazykové jednotky do číselnej podoby tak, aby táto reprezentácia zachytávala aj ich významové vlastnosti. Na rozdiel od klasických prístupov, ktoré text opisujú najmä prostredníctvom výskytu jednotlivých termínov, embeddingové reprezentácie sa snažia vyjadriť vzťahy medzi slovami, vetami alebo dokumentmi v spojitom vektorovom priestore. Základnou myšlienkou embeddingov je teda reprezentovať jazykové objekty tak, aby si významovo príbuzné jednotky boli v tomto priestore navzájom bližšie ako jednotky významovo vzdialené [16, 15].

Kľúčovým rozdielom medzi klasickými a modernejšími prístupmi k reprezentácii textu je to, či ide o riedke alebo husté reprezentácie. Riedke reprezentácie, ako napríklad bag-of-words alebo TF-IDF, bývajú viazané na konkrétny slovník termínov a vektory v nich obsahujú veľké množstvo nulových hodnôt. Husté reprezentácie naopak vyjadrujú text pomocou menšieho počtu číselných rozmerov, pričom jednotlivé rozmery nenesú iba informáciu o prítomnosti konkrétnych slov, ale aj o ich širších významových a kontextových vzťahoch. Táto vlastnosť robí embeddingy vhodnými pre úlohy, v ktorých nestačí sledovať len presnú zhodu slov, ale je potrebné zachytiť aj sémantickú podobnosť medzi textami [16].

Sémantická reprezentácia textu umožňuje systému pracovať s obsahovou blízkosťou textov aj vtedy, keď sa nezhodujú na úrovni identických termínov. V klasických modeloch môže byť problémom to, že dva texty hovoria o podobnej téme odlišnými slovami, a preto sa ich podobnosť na základe frekvencie termínov nemusí prejaviť dostatočne presne. Embeddingové prístupy sa snažia tento problém zmierniť tým, že zachytávajú významové vzťahy medzi jazykovými jednotkami a umožňujú tak robustnejšie porovnávanie textov z hľadiska ich obsahu, nie iba z pohľadu ich povrchovej slovnej podoby [16, 15].

Významné miesto medzi modernými NLP modelmi zaujímajú modely založené na architektúre BERT. Tieto modely vychádzajú z transformerovej architektúry, pričom jadrom prístupu je predtrénovanie hlbokých bidirekčných jazykových reprezentácií na veľkých objemoch neoznačeného textu. Charakteristickou črtou modelu BERT je, že pri spracovaní textu zohľadňuje kontext z oboch strán, čím umožňuje vytvárať bohatšie reprezentácie jazykových jednotiek než staršie sekvenčné alebo jednostranne orientované modely. Predtrénovaný model možno následne doladiť na konkrétne úlohy, ako sú klasifikácia textu, otázkovo-odpoveďové systémy alebo rozpoznávanie významových vzťahov medzi vetami [16].

Pre úlohy porovnávania viet, kratších textov a sémantického vyhľadávania však základný model BERT nie je vždy najpraktickejší. Pri priamom porovnávaní dvojíc viet totiž vyžaduje opakované spoločné spracovanie porovnávaných vstupov, čo je výpoč-

tovo náročné. Práve preto vznikol model Sentence-BERT, ktorý upravuje architektúru BERT tak, aby bolo možné vytvárať samostatné vetné embeddingy vhodné na rýchle porovnávanie pomocou cosine similarity. Takto vytvorené reprezentácie umožňujú efektívnejšie vyhľadávanie sémanticky podobných viet a kratších textových jednotiek, pričom si zachovávajú dobrú kvalitu pri úlohách sémantickej podobnosti [15].

Z pohľadu informačných a odporúčacích systémov predstavujú embeddingy významný posun oproti klasickým textovým reprezentáciám. Umožňujú pracovať nielen s presnými termínmi, ale aj s významovými súvislosťami medzi textami. To je dôležité najmä pri odporúčaní obsahovo príbuzných dokumentov a pri vyhľadávaní relevantných výsledkov v prípadoch, keď používateľ alebo dokumenty používajú odlišné slovné vyjadrenie tej istej témy. Modely založené na architektúre BERT a ich úpravy, ako je Sentence-BERT, preto predstavujú dôležitý základ moderných prístupov k sémantickej reprezentácii textu [16, 15].

2.6 Obsahové odporúčanie vedeckých článkov

Obsahové odporúčanie je prístup, pri ktorom systém navrhuje používateľovi položky podobné tým, ktoré v minulosti preferoval. Základným princípom content-based odporúčania je teda práca s obsahovým opisom položiek a s reprezentáciou používateľských záujmov. Odporúčací mechanizmus nevychádza primárne z preferencií iných používateľov, ale z porovnávania vlastností objektov s profilom konkrétného používateľa. Takýto prístup patrí medzi základné personalizačné techniky informačných systémov a je zvlášť vhodný tam, kde sú k dispozícii dobre opísané položky a ich textové alebo metadátové charakteristiky [17, 18].

Pri tvorbe odporúčaní na základe vlastností článku je dôležité, aby bol každý dokument reprezentovaný prostredníctvom takých znakov, ktoré čo najlepšie vystihujú jeho obsah. V prípade vedeckých článkov môžu túto úlohu plniť napríklad názov, abstrakt, kľúčové slová, kategórie alebo ďalšie metadáta. Odporúčanie sa potom vytvára na základe podobnosti medzi reprezentáciami článkov, systém predpokladá, že ak používateľ v minulosti prejavil záujem o určité dokumenty, budú pre neho relevantné aj obsahovo podobné články. Kvalita týchto odporúčaní pritom priamo závisí od toho, ako presne použitá reprezentácia zachytáva obsah článku [18].

Dôležitou súčasťou content-based odporúčania je vytváranie používateľského profilu. Používateľský profil predstavuje model preferencií, ktorý sa odvodzuje z položiek, s ktorými používateľ v minulosti pracoval alebo ktoré označil ako zaujímavé. Pri obsahovom odporúčaní sa profil zvyčajne vytvára agregáciou vlastností preferovaných položiek, čím vzniká reprezentácia používateľských záujmov. Odporúčací systém potom porovnáva profil používateľa s reprezentáciami kandidátnych položiek a vyberá

tie, ktoré sú profilovým charakteristikám najbližšie. Tento princíp je vhodný aj pri odporúčaní vedeckých článkov, keďže záujem používateľa možno odvodzovať z článkov, ktoré tematicky zodpovedajú jeho predchádzajúcim preferenciám [17, 18].

Výhodou obsahového odporúčania je najmä to, že dokáže pracovať aj v situáciách, keď nie sú k dispozícii rozsiahle údaje o hodnoteniach od veľkého množstva používateľov. Systém môže odporúčať nové položky na základe ich vlastností a individuálnych preferencií konkrétneho používateľa, čo je výhodné najmä pri menších alebo špecializovaných kolekciiach dokumentov. Zároveň ide o prístup, ktorý je do určitej miery interpretovateľný, pretože odporúčanie možno spätne zdôvodniť podobnosťou obsahových charakteristík medzi preferovanými a odporúčanými položkami [18].

Na druhej strane má content-based odporúčanie aj viaceré limity. Kvalita odporúčania je silne závislá od kvality a úplnosti reprezentácie položiek, pričom slabšie alebo nepresné metadáta môžu znižovať presnosť výsledkov. Ďalším obmedzením je tendencia odporúčať používateľovi obsah podobný tomu, ktorý už pozná, čo môže viesť k nižšej rozmanitosti odporúčaní. V prípade vedeckých článkov sa zároveň ukazuje, že samotná obsahová podobnosť nemusí vždy postačovať a v niektorých riešeniach sa preto dopĺňa ďalšími zdrojmi informácií, napríklad citačnými vzťahmi medzi článkami. [18, 7].

Obsahové odporúčanie tak tvorí prirodzený základ pre systém, kde kvalitné metadáta a textové reprezentácie článkov hrajú kľúčovú úlohu [17, 18].

2.7 Spracovanie PDF a význam metadát

V systémoch určených na správu vedeckých článkov predstavuje PDF jeden z najčastejšie využívaných formátov dokumentov. Ide o štandardizovanú podobu, ktorá umožňuje uchovávať text, formátovanie aj ďalšie vizuálne prvky v stabilnej a prenosnej forme. Z pohľadu informačného systému však samotný PDF súbor nepostačuje na efektívne vyhľadávanie, organizáciu a ďalšie spracovanie odborného obsahu. Aby bolo možné dokumenty spoľahlivo spravovať a sprístupňovať, je potrebné doplniť ich o kvalitne spracované metadáta, ktoré zachytávajú základné identifikačné a obsahové charakteristiky dokumentu.

Metadáta zohrávajú pri správe odborných dokumentov zásadnú úlohu, pretože predstavujú štruktúrovaný opis dokumentu a podporujú jeho evidenciu, vyhľadávanie, triedenie aj ďalšie spracovanie. Kvalita metadát pritom výrazne ovplyvňuje kvalitu práce celého systému. Zdôrazňuje sa najmä význam presnosti, úplnosti a konzistencie metadát, keďže práve tieto vlastnosti rozhodujú o tom, do akej miery dokážu metadáta plniť základné funkcie, ako sú objaviteľnosť, použiteľnosť a dôveryhodná identifikácia digitálnych objektov [19].

Význam metadát v súčasnom ekosystéme vedeckej komunikácie potvrdzujú aj roz-

siahle scholarly metadata infraštruktúry. Metadátové záznamy dnes nezahŕňajú iba základné bibliografické údaje, ale môžu obsahovať aj abstrakty, odkazy na plné texty, citačné prepojenia, informácie o financovaní, licenciách alebo aktualizáciách publikácie. Takto koncipované metadáta vytvárajú základ nielen pre evidenciu dokumentov, ale aj pre ich prepojenie, interoperabilitu a efektívne vyhľadávanie v digitálnom prostredí [20].

Osobitný význam majú pri reprezentácii obsahu článku názov, abstrakt a kľúčové slová. Tieto prvky predstavujú najdôležitejšie textové polia, prostredníctvom ktorých je článok identifikovaný vo vyhľadávačoch, databázach a ďalších informačných systémoch. V digitálnom prostredí sa zdôrazňuje, že strategické a obsahovo presné použitie termínov v názve, abstrakte a kľúčových slovách môže zlepšiť indexovanie, nájdnosť aj celkovú viditeľnosť vedeckého článku [5]. Podobne sa poukazuje aj na to, že akademické vyhľadávače nemusia pracovať so všetkými časťami dokumentu rovnako a že niektoré z nich prikladajú osobitnú váhu práve vybraným metadátovým a textovým poliam [3].

Pri systémoch pracujúcich s vedeckými článkami preto metadáta neplnia iba evidenčnú funkciu, ale predstavujú aj významný základ pre obsahovú reprezentáciu dokumentu. Názov, abstrakt, kľúčové slová, autori alebo kategórie môžu slúžiť ako vstup pre textové modely, ktoré následne umožňujú porovnávanie dokumentov a odporúčanie obsahovo príbuzných článkov. Spracovanie PDF dokumentov je tak v praxi úzko previazané s extrakciou, uchovávaním a využitím metadát, ktoré tvoria spojenie medzi samotným dokumentom a funkciami informačného alebo odporúčacieho systému [19, 3].

Kapitola 3

Analýza východiskového systému a požiadavky na rozšírenie

3.1 Východiskový stav systému

Východiskom diplomovej práce bol existujúci prototyp systému vytvorený v rámci bakalárskej práce. Jeho cieľom bolo poskytnúť lokálne hostované riešenie na evidovanie, správu a zdieľanie vedeckých článkov. Pôvodný systém bol navrhnutý ako praktický nástroj pre individuálnu aj skupinovú prácu s odbornou literatúrou a zároveň predstavoval základ pre ďalšie rozšírenie v diplomovej práci.

Pôvodné riešenie už obsahovalo niekoľko základných funkcií. Systém umožňoval pridávať články spolu s PDF súbormi a pracovať s ich metadátami, najmä s názvom, obsahom alebo abstraktom, autormi, kategóriami a kľúčovými slovami. Súčasťou riešenia bolo aj vyhľadávanie článkov podľa názvu, autora, kľúčových slov alebo tagov, export bibliografických záznamov, označovanie článkov medzi obľúbené a práca s verejnými a súkromnými tagmi. Okrem toho systém podporoval vytváranie skupín, posielanie pozvánok a skupinové označovanie článkov, čím vytváral základ pre jednoduchú kolaboratívnu prácu s odbornou literatúrou.

Z technologického hľadiska bol pôvodný systém realizovaný ako webová aplikácia s oddelenou frontendovou a backendovou vrstvou. Frontend zabezpečoval používateľské rozhranie pre vyhľadávanie, profil používateľa a skupinové stránky, zatiaľ čo backend poskytoval aplikačnú logiku a API pre správu článkov, metadát, používateľských interakcií a skupín. Dátová vrstva bola založená na relačnom modeli, v ktorom tvorili základ entity používateľa, článku, autora, kategórie, kľúčového slova, tagu a skupiny. Takto navrhnutý systém predstavoval funkčný základ, na ktorý bolo možné ďalej nadviazať v diplomovej práci.

3.1.1 Identifikované obmedzenia pôvodného riešenia

Napriek tomu, že pôvodný systém pokrýval základné potreby evidencie a zdieľania odborných článkov, jeho analýza ukázala viacero obmedzení. V prvom rade v ňom absentovalo personalizované odporúčanie obsahu. Používateľ síce mohol články vyhľadávať, ukladať medzi obľúbené alebo s nimi pracovať v rámci skupiny, systém však na základe tejto aktivity nedokázal automaticky odporúčať ďalšie relevantné články.

Ďalším obmedzením bola absencia funkcie podobných článkov. Pôvodné riešenie neponúkalo mechanizmus, ktorý by pri konkrétnom článku automaticky vyhľadal obsahovo príbuzné dokumenty. To znížovalo možnosti objavovania ďalších relevantných zdrojov priamo počas práce so systémom.

Za obmedzenie možno považovať aj spôsob práce s používateľskou spätnou väzbou. Systém síce evidoval základné interakcie, napríklad obľúbené články alebo skupinové označenia, no tieto údaje sa ďalej nevyužívali na inteligentnejšie prispôbovanie správaní systému konkrétnemu používateľovi.

Isté limity sa prejavovali aj na úrovni používateľského rozhrania. Pôvodný frontend poskytoval funkčný základ, avšak pri ďalšom rozširovaní systému už nepostačoval z hľadiska prehľadnosti, používateľskej prístupnosti ani vizuálnej konzistentnosti. Z tohto dôvodu vznikla potreba jeho modernizácie a úpravy tak, aby lepšie podporoval nové funkcionality aj pohodlnejšiu prácu používateľa.

3.2 Požiadavky na rozšírenie systému

3.2.1 Use cases

Z pohľadu rozšírenia systému boli identifikovaní hlavní aktéri, ktorí vstupujú do interakcie s aplikáciou. Základnú rolu predstavuje neprihlásený návštevník, ktorý môže pristupovať k verejne dostupným častiam systému a vyhľadávať články. Kľúčovým aktérom je prihlásený používateľ, ktorý môže pracovať s vlastnými článkami, obľúbenými článkami, personalizovanými odporúčaniami a ďalšími funkciami naviazanými na používateľský účet. Pri skupinových scenároch vystupuje ako samostatný aktér člen skupiny, prípadne administrátor skupiny, ktorý má rozšírené oprávnenia pri správe skupiny a jej členov.

Z pohľadu diplomovej práce sú najdôležitejšie tie scenáre, ktoré súvisia s rozšírením systému o odporúčacie mechanizmy a skupinovú interakciu. Medzi kľúčové use cases preto patria zobrazenie podobných článkov, získanie personalizovaných odporúčaní, poskytovanie spätnej väzby na odporúčaný obsah a diskusia v skupinách.

Zobrazenie podobných článkov

Pri scenári zobrazenia podobných článkov vystupuje ako hlavný aktér prihlásený alebo neprihlásený používateľ, ktorý pracuje s detailom konkrétneho článku. Cieľom scenára je umožniť používateľovi získať zoznam obsahovo príbuzných článkov bez potreby opakovaného manuálneho vyhľadávania. Používateľ vyhledá požadovaný článok, otvorí detail vybraného článku a následne aktivuje funkciu zobrazenia podobných článkov. Systém na základe textovej reprezentácie aktuálneho článku vypočíta podobnosť voči ostatným článkom v databáze a zobrazí používateľovi zoznam najrelevantnejších výsledkov.

Získanie personalizovaných odporúčaní


Pri scenári získania personalizovaných odporúčaní vystupuje ako hlavný aktér prihlásený používateľ. Cieľom scenára je ponúknuť používateľovi články, ktoré zodpovedajú jeho doterajším preferenciám a interakciám so systémom. Používateľ otvorí profilovú časť aplikácie, v ktorej sa nachádza sekcia odporúčaných článkov. Systém pri generovaní odporúčaní vychádza z článkov, ktoré používateľ označil ako obľúbené, zo skupinových interakcií a z predchádzajúcej spätnej väzby na odporúčania. Výsledkom scenára je zobrazenie personalizovaného zoznamu článkov, ktoré majú pre používateľa najvyššiu predpokladanú relevanciu.

Poskytnutie spätnej väzby na odporúčania


Na scenár poskytovania spätnej väzby nadväzuje scenár personalizovaných odporúčaní. Aktérom je opäť prihlásený používateľ, ktorý po zobrazení odporúčaného obsahu môže vyjadriť svoju reakciu na odporúčaný článok. Používateľ môže odporúčaný článok potvrdiť ako relevantný, napríklad jeho označením medzi obľúbené, alebo ho naopak odmietnuť. Systém túto interakciu zaznamená a využije ju pri ďalšej aktualizácii odporúčaní. Význam tohto scenára spočíva v tom, že systém nepracuje iba so statickým profilom používateľa, ale dokáže reagovať aj na priebežnú spätnú väzbu a prispôbovať ďalšie odporúčania aktuálnemu správaniu používateľa.

Diskusia a komentovanie v skupine

Pri scenári diskusie a komentovania v skupine vystupuje ako hlavný aktér člen skupiny. Používateľ vstúpi do detailu skupiny a otvorí skupinovú diskusiu v skupine v ktorej je členom. V rámci nej môže vytvárať nové správy, reagovať na existujúce správy, označovať iných členov skupiny a v prípade potreby prepájať správu s konkrétnym článkom.



Obr. 3.1: Use case diagram scenára zobrazenia podobných článkov



Obr. 3.2: Use case diagram scenára získania personalizovaných odporúčaní a spracovania spätnej väzby

3.2.2 Funkčné požiadavky

- **PF1** Systém musí umožniť zobrazenie obsahovo podobných článkov pre konkrétny článok na základe vypočítanej podobnosti textových reprezentácií.
- **PF2** Systém musí umožniť generovanie personalizovaných odporúčaní pre používateľa na základe jeho interakcií s článkami.
- **PF3** Systém musí zaznamenávať interakcie používateľa relevantné pre odporúčanie obsahu, najmä obľúbené články, skupinové označenia, pozitívnu spätnú väzbu a odmietnutie odporúčaní.
- **PF4** Systém musí pri odporúčaní zohľadňovať nielen individuálne preferencie používateľa, ale aj relevantné skupinové interakcie.
- **PF5** Systém musí umožniť aktualizáciu odporúčaní po zmene vstupných údajov alebo po novej používateľskej interakcii.
- **PF6** Systém musí podporovať použitie najmenej dvoch modelov textovej reprezentácie článkov, aby ich bolo možné porovnať v experimentálnej časti práce.
- **PF7** Systém musí umožniť používateľovi prepínať medzi dostupnými modelmi odporúčania, ak je táto funkcionality prístupná v používateľskom rozhraní.
- **PF8** Systém musí umožniť skupinovú diskusiu, vytváranie správ, odpovedanie na správy a označovanie používateľov v rámci skupiny.

3.2.3 Nefunkčné požiadavky

- **PN1** Systém musí byť dostupný prostredníctvom webového rozhrania bez potreby inštalácie samostatného klienta.
- **PN2** Systém musí poskytovať primeranú odozvu pri bežných operáciách, najmä pri vyhľadávaní, práci s profilom používateľa a zobrazovaní odporúčaní.
- **PN3** Systém musí zabezpečiť konzistentné a spoľahlivé ukladanie údajov o článkoch, používateľoch, skupinách a interakciách.
- **PN4** Používateľské rozhranie musí byť prehľadné, konzistentné a musí umožniť jednoduchú orientáciu medzi hlavnými časťami systému.
- **PN5** Dôležité akcie systému musia byť používateľovi ľahko dostupné a výsledok vykonaných operácií musí byť zrozumiteľne komunikovaný.

- **PN6** Databázový model a aplikačná logika musia byť navrhnuté tak, aby bolo možné systém ďalej rozširovať o nové entity, interakcie a odporúčacie mechanizmy.

Kapitola 4

Návrh systému

4.1 Celkový návrh architektúry systému

4.2 Návrh dátového a databázového modelu

4.3 Návrh funkcie „Similar to this article“

4.4 Návrh funkcie „Recommended for you“

Kapitola 5

Implementácia rozšíreného systému

- 5.1 Modernizácia frontendovej vrstvy
- 5.2 Implementácia textových reprezentácií článkov
- 5.3 Implementácia funkcie „Similar to this article“
- 5.4 Implementácia funkcie „Recommended for you“
- 5.5 Implementácia spracovania spätnej väzby

Kapitola 6

Experimentálne vyhodnotenie

6.1 Cieľ experimentu a výskumná otázka

Cieľom experimentálnej časti tejto diplomovej práce je overiť kvalitu navrhnutého odporúčacieho systému pre vedecké články pri personalizovanom odporúčaní a porovnať správanie dvoch použitých prístupov k reprezentácii textového obsahu, konkrétne metódy TF-IDF a modelu Sentence-BERT. Experimentálne vyhodnotenie nadväzuje na implementačnú časť práce a zameriava sa na to, do akej miery dokážu jednotlivé modely pracovať s obsahom článkov tak, aby boli výsledné odporúčania pre konkrétneho používateľa relevantné a tematicky zmysluplné.

V experimentálnej časti je sledovaná funkcia *Recommended for you*, ktorá vytvára personalizované odporúčania na základe používateľských interakcií. Systém pritom vychádza najmä z článkov, ktoré používateľ označil ako obľúbené, a v rozšírenom scenári aj z ďalších signálov správania, ako sú skupinové preferencie, pozitívna spätná väzba a odmietnutie odporúčaných článkov. Experimentálne vyhodnotenie preto nesleduje iba všeobecnú úspešnosť modelov, ale aj ich vhodnosť pre rôzne úrovne personalizácie v prostredí vedeckých článkov.

Hlavnou výskumnou otázkou tejto práce je, ktorý z porovnávaných prístupov, teda TF-IDF alebo Sentence-BERT, poskytuje kvalitnejšie výsledky pri personalizovanom odporúčaní vedeckých článkov. Táto otázka sa ďalej sleduje v dvoch experimentálnych scenároch. Prvým je základný experiment, v ktorom sa používateľský profil vytvára iba zo základných interakcií vo forme označených obľúbených článkov. Druhým je rozšírený experiment, v ktorom sa profil používateľa vytvára realistickejšie a zohľadňuje viaceré typy interakcií, ako sú používateľské lajky, skupinové lajky, pozitívna spätná väzba a odmietnuté odporúčania. Cieľom je zistiť, ako sa oba modely správajú v jednoduchšom aj komplexnejšom personalizačnom scenári.

Porovnanie metód TF-IDF a Sentence-BERT má v kontexte tejto práce význam z viacerých dôvodov. TF-IDF predstavuje tradičný a dobre známy prístup k reprezentá-

cii textu, ktorý vychádza z frekvencie slov a ich informatívnosti v rámci celej kolekcie dokumentov. Jeho výhodou je jednoduchosť, nízka výpočtová náročnosť a dobrá interpretovateľnosť. Na druhej strane Sentence-BERT predstavuje modernejší prístup založený na hustých vektorových reprezentáciách, ktorý dokáže lepšie zachytávať význam textu a sémantické vzťahy medzi dokumentmi. Práve pri personalizovanom odporúčaní vedeckých článkov môže byť schopnosť zachytiť významovú podobnosť dôležitá, keďže relevantné články pre používateľa nemusia vždy obsahovať presne rovnaké kľúčové slová alebo slovné spojenia ako články, s ktorými už interagoval.

Experimentálna časť má preto za úlohu nielen kvantitatívne porovnať výsledky oboch modelov pomocou zvolených metrík, ale aj interpretovať ich správanie v kontexte navrhnutého systému. Dôležité je zistiť, či modernejší sémantický model prináša v prostredí vedeckých článkov reálny prínos oproti klasickému štatistickému prístupu, alebo či v niektorých personalizačných scenároch ostáva jednoduchšia metóda TF-IDF stále konkurencieschopným riešením. Výsledky experimentov tak budú slúžiť ako podklad pre zodpovedanie výskumnej otázky a zároveň pre zhodnotenie vhodnosti jednotlivých prístupov pre praktické nasadenie v personalizovanom odporúčacom systéme.

6.2 Dataset a príprava dát

Experimentálne vyhodnotenie bolo realizované na vlastnom datasete vedeckých článkov, ktorý bol pripravený špeciálne pre potreby tejto práce. Dataset obsahuje spolu 250 článkov z viacerých tematických oblastí, pričom zastúpené sú najmä oblasti *computer vision*, *deep learning*, *autonomous driving*, *multimodal systems*, *recommender systems*, *information retrieval*, *natural language processing*, *medical AI*, *modeling*, *time series*, *optimization*, *empirical studies* a *misc*. Cieľom takto zostaveného datasetu bolo vytvoriť dostatočne rôznorodé, ale zároveň tematicky konzistentné prostredie, v ktorom bude možné sledovať správanie odporúčacieho systému pri personalizovanom odporúčaní vedeckých článkov.

Pri zostavovaní datasetu bol dôraz kladený na kvalitu textových metadát, keďže práve tie tvoria základ vstupu pre oba porovnávané modely. Každý článok bol preto do systému zaradený s čo najpresnejším názvom, abstraktom, množinou kľúčových slov, menami autorov a hlavnou tematickou kategóriou. Z pohľadu odporúčania vedeckých článkov bol za najdôležitejší atribút považovaný abstrakt článku, pretože najlepšie vystihuje jeho obsah a odborné zameranie. Kľúčové slová a kategórie slúžili ako doplnkové informácie, ktoré pomáhali spresniť tematický profil dokumentu, zatiaľ čo názov a autori poskytovali ďalší kontext vhodný na reprezentáciu článku.

Dataset bol zároveň navrhnutý tak, aby umožňoval vytváranie tematicky odlišných používateľských profilov. Jednotlivé články boli rozdelené medzi viaceré tematické ob-

lasti tak, aby bolo možné simulovať používateľov s dominantným odborným zameraním, ale aj s čiastočným presahom do príbuzných tém. Takto pripravené dáta vytvárali vhodný základ pre experimenty zamerané na porovnanie kvality personalizovaných odporúčaní generovaných modelmi TF-IDF a Sentence-BERT.

Pred samotnou vektorizáciou boli tieto atribúty spojené do jedného spoločného textového vstupu. Pre každý článok tak vznikol jeden textový reťazec, ktorý obsahoval názov, abstrakt, zoznam kľúčových slov, názvy kategórií a mená autorov. Takto pripravený text predstavoval jednotný vstup pre oba porovnávané prístupy. Výhodou tohto riešenia bolo, že oba modely pracovali s rovnakým informačným základom, a ich výsledky preto bolo možné férovo porovnať.

Pri metóde TF-IDF bol z takto vytvoreného korpusu zostavený riedky vektorový priestor, v ktorom jednotlivé rozmery zodpovedali slovám alebo dvojiciam slov a ich váham v rámci celej kolekcie dokumentov. Táto reprezentácia bola závislá od celého korpusu článkov, preto bolo po finálnom doplnení datasetu potrebné prepočítať TF-IDF reprezentáciu pre všetky články nanovo. Pri modeli Sentence-BERT bol pre každý článok vytvorený hustý embedding reprezentujúci význam celého textového vstupu. Na rozdiel od TF-IDF je tento typ reprezentácie vytváraný pre každý článok samostatne, pričom lepšie zachytáva sémantickú podobnosť medzi textami aj v prípadoch, keď sa v nich nepoužívajú úplne rovnaké výrazy.

Takto pripravené vektorové reprezentácie tvorili základ pre experimentálne porovnanie oboch prístupov v úlohe personalizovaného odporúčania. Keďže oba modely vychádzali z rovnakých článkov a rovnakých textových vstupov, rozdiely vo výsledkoch bolo možné interpretovať ako dôsledok rozdielného spôsobu reprezentácie obsahu vedeckých článkov.

6.3 Metodika hodnotenia

Experimentálne vyhodnotenie navrhnutého systému bolo rozdelené do dvoch častí. Cieľom bolo porovnať správanie modelov TF-IDF a Sentence-BERT pri personalizovanom odporúčaní článkov používateľovi v rámci funkcie *Recommended for you*. Jednotlivé experimenty boli navrhnuté tak, aby postupne overovali systém od jednoduchšieho a kontrolovaného scenára až po realistickejšie situácie s viacerými typmi interakcií.

Prvý experiment bol zameraný na základné vyhodnotenie funkcie *Recommended for you*. V tomto experimente bolo použitých 10 používateľov, pričom každý z nich mal vytvorených 15 interakcií typu *like*. Tieto interakcie boli tematicky rozdelené tak, aby reprezentovali relatívne konzistentný používateľský profil. Pre každého používateľa bolo následne 12 označení *like* použitých ako tréningová časť na vytvorenie používateľského profilu a zvyšné 3 označenia tvorili testovaciu časť. Úlohou systému bolo na

základe trérovacej časti odporučiť články, pričom sa následne vyhodnocovalo, či sa medzi odporúčanými článkami nachádzali aj články z testovacej množiny.

Druhý experiment predstavoval rozšírený scenár pre funkciu *Recommended for you*. V tomto prípade sa už nepracovalo iba s jednoduchými interakciami typu *like*, ale aj s ďalšími používateľskými a skupinovými signálmi. Zohľadnené boli najmä explicitné označenia *like*, pozitívna spätná väzba na odporúčané články, negatívna spätná väzba vo forme odmietnutia odporúčania a interakcie vyplývajúce zo skupinového prostredia, napríklad skupinové označenia článkov ako obľúbených. Cieľom tohto experimentu bolo overiť, ako sa správanie modelov mení v realistickejšom prostredí, v ktorom používateľský profil nevzniká len z jednej formy interakcie, ale z kombinácie viacerých signálov.

Spôsob generovania odporúčaní bol v oboch porovnávaných prístupoch založený na rovnakej logike, pričom sa menila iba použitá vektorová reprezentácia článkov. Každý článok bol najskôr prevedený na číselný vektor pomocou modelu TF-IDF alebo Sentence-BERT. Pri personalizovanom odporúčaní bol z trérovacích interakcií používateľa vytvorený používateľský profil, ktorý reprezentoval jeho preferencie vo vektorovom priestore. Následne sa pomocou kosínusovej podobnosti porovnal tento profil s vektormi ostatných článkov a systém vrátil články s najvyššou podobnosťou.

Pri druhom, rozšírenom experimente však nebolo možné pripraviť pozitívnu a negatívnu spätnú väzbu spoločne pre oba modely. Dôvodom bolo, že modely TF-IDF a Sentence-BERT generovali odlišné zoznamy odporúčaných článkov, a teda používateľská spätná väzba musela byť vždy naviazaná na konkrétny model a jeho vlastné odporúčania. Z metodického hľadiska preto bolo potrebné postupovať oddelene. Najskôr bol celý scenár s pozitívnym a negatívnym feedbackom vyhodnotený pre model TF-IDF, následne bol používateľský profil resetovaný do pôvodného stavu a rovnaký postup bol samostatne zopakovaný pre model Sentence-BERT. Takýto prístup zabezpečil, že spätná väzba v druhom experimente nevznikala na základe zmiešaných odporúčaní oboch modelov, ale vždy iba na základe odporúčaní jedného konkrétného prístupu.

Na vyhodnotenie kvality odporúčaní boli použité štyri štandardné metriky, a to *Precision@K*, *Recall@K*, *MAP@K* a *nDCG@K*. Metrika *Precision@K* vyjadruje podiel relevantných článkov medzi prvými K odporúčaniami. *Recall@K* naopak vyjadruje, akú časť všetkých relevantných článkov sa podarilo systému nájsť v prvých K výsledkoch. Metrika *MAP@K* zohľadňuje nielen to, či boli relevantné články nájdené, ale aj to, na akých pozíciách sa v odporúčanom zozname nachádzali. Metrika *nDCG@K* hodnotí kvalitu poradia odporúčaní so silnejším dôrazom na vyššie pozície v zozname výsledkov. V experimentoch boli tieto metriky vyhodnocované najmä pre hodnoty $K = 5$ a $K = 10$, aby bolo možné porovnať kvalitu najužšieho zoznamu odporúčaní aj širšieho zoznamu výsledkov.

Takto navrhnutá metodika umožňuje porovnať oba modely z viacerých pohľadov.

Na jednej strane je možné sledovať, ktorý model dokáže nájsť väčší počet relevantných článkov, a na druhej strane aj to, ktorý model ich dokáže lepšie zoradiť v rámci výsledného odporúčacieho zoznamu. Vďaka tomu je možné experimentálne vyhodnotenie postaviť nielen na jednom ukazovateli, ale na komplexnejšom pohľade na kvalitu personalizovaného odporúčania.

6.4 Experiment 1 – Vyhodnotenie funkcie „Recommended for you“

6.4.1 Základný experiment personalizovaných odporúčaní

Cieľom základného experimentu bolo overiť kvalitu funkcie *Recommended for you* v kontrolovanom scenári, v ktorom bol používateľský profil vytváraný výhradne na základe explicitných označení *like*. Zmyslom tohto nastavenia bolo porovnať modely TF-IDF a Sentence-BERT v čo najčistejších podmienkach, bez vplyvu skupinových interakcií alebo ďalších doplnkových signálov správania. Takýto prístup umožnil sledovať, ako sa oba modely správajú pri základnej forme personalizácie, keď systém vychádza len z článkov, ktoré používateľ označil ako relevantné.

V experimente bolo použitých 10 používateľov, pričom každému z nich bolo priradených 15 interakcií typu *like*. Tieto interakcie boli navrhnuté tak, aby reprezentovali tematicky konzistentný profil používateľa, založený na jednej dominantnej oblasti a menšom presahu do príbuzných tém. Z celkového počtu 15 označení *like* bolo pre každého používateľa 12 použitých na vytvorenie používateľského profilu a zvyšné 3 tvorili testovaciu množinu relevantných článkov. Trénovacia časť teda predstavovala historické preferencie používateľa, ktoré mal systém k dispozícii, zatiaľ čo testovacia časť slúžila na overenie toho, či model dokázal medzi odporúčanými článkami identifikovať aj tie, ktoré používateľ v skutočnosti preferoval.

Používateľský profil bol v oboch porovnávaných prístupoch vytvorený rovnakým spôsobom. Najskôr boli všetky články reprezentované ako vektory pomocou modelu TF-IDF alebo Sentence-BERT. Následne sa z vektorov článkov, ktoré patrili do trénovacej množiny konkrétneho používateľa, vytvoril profilový vektor. Tento profil reprezentoval tematické preferencie používateľa vo vektorovom priestore a slúžil ako základ pre generovanie odporúčaní. Pomocou kosínusovej podobnosti sa potom profilový vektor porovnal s vektormi ostatných článkov v databáze a systém vrátil zoznam článkov s najvyššou podobnosťou. Výsledkom bol zoradený zoznam odporúčaní, z ktorého sa následne vyhodnocovalo, či obsahoval aj články z testovacej množiny.

Vyhodnotenie bolo realizované pomocou metrík Precision@5, Recall@5, MAP@5, nDCG@5, Precision@10, Recall@10, MAP@10 a nDCG@10. Tieto metriky umožnili


posúdiť nielen to, koľko relevantných článkov model našiel, ale aj to, ako dobre ich zoradil na vyššie pozície odporúčaného zoznamu.

Výsledky pre hodnotu $K = 5$ sú uvedené v tabuľke 6.1. Z týchto hodnôt vyplýva, že model Sentence-BERT dosiahol lepšie výsledky v metrikách Precision@5 a Recall@5, teda dokázal v priemere zaradiť do odporúčaní o niečo viac relevantných článkov a zachytiť väčšiu časť testovacej množiny. Model TF-IDF naopak dosiahol vyššie hodnoty MAP@5 a nDCG@5, čo naznačuje, že pri nájdení relevantných článkov ich vedel mierne lepšie zoradiť na vyššie pozície v zozname odporúčaní.

Tabuľka 6.1: Porovnanie výsledkov modelov TF-IDF a Sentence-BERT pre $K = 5$

Model	Precision@5	Recall@5	MAP@5	nDCG@5
TF-IDF	0,1400	0,2333	0,1511	0,2243
SBERT	0,1600	0,2667	0,1361	0,2152

Grafické porovnanie výsledkov pre $K = 5$ je znázornené na obrázku 6.1. Z grafu je dobre viditeľné, že rozdiely medzi modelmi nie sú výrazné, no zároveň možno pozorovať miernu prevahu modelu Sentence-BERT v presnosti a pokrytí relevantných článkov a miernu prevahu modelu TF-IDF v kvalite zoradenia výsledkov.



Obr. 6.1: Porovnanie výsledkov modelov TF-IDF a Sentence-BERT pre $K = 5$


Výsledky pre hodnotu $K = 10$ sú uvedené v tabuľke 6.2. Aj pri širšom zozname odporúčaní sa potvrdil podobný trend ako pri $K = 5$. Sentence-BERT dosiahol lepšie hodnoty Precision@10 a Recall@10, čo znamená, že vo väčšom zozname odporúčaní našiel viac relevantných článkov. TF-IDF si opäť zachoval miernu prevahu v metri-

kách MAP@10 a nDCG@10, čo poukazuje na o niečo lepšie zoradenie relevantných výsledkov.

Tabuľka 6.2: Porovnanie výsledkov modelov TF-IDF a Sentence-BERT pre $K = 10$


Model	Precision@10	Recall@10	MAP@10	nDCG@10
TF-IDF	0,1000	0,3333	0,1669	0,2675
SBERT	0,1100	0,3667	0,1603	0,2603

Grafické porovnanie výsledkov pre $K = 10$ je znázornené na obrázku 6.2. Pri tejto hodnote K je rozdiel medzi modelmi ešte zreteľnejší najmä v metrike Recall@10, kde Sentence-BERT dosiahol najvyššiu hodnotu spomedzi všetkých sledovaných metrík. To naznačuje, že pri širšom zozname odporúčaní dokázal lepšie pokryť používateľove relevantné články.



Obr. 6.2: Porovnanie výsledkov modelov TF-IDF a Sentence-BERT pre $K = 10$

Pre lepšiu interpretáciu rozdielov medzi modelmi je na obrázku 6.3 zobrazený aj graf rozdielov jednotlivých metrík, kde kladné hodnoty znamenajú lepší výsledok modelu Sentence-BERT a záporné hodnoty lepší výsledok modelu TF-IDF. Z tohto porovnania vyplýva, že Sentence-BERT prekonal TF-IDF v metrikách Precision a Recall pre obe hodnoty K , zatiaľ čo TF-IDF bol mierne lepší v metrikách MAP a nDCG. Tento výsledok potvrdzuje, že oba modely mali v experimente odlišné silné stránky.



Obr. 6.3: Rozdiely medzi výsledkami modelov Sentence-BERT a TF-IDF v jednotlivých metrikách

Z výsledkov základného experimentu vyplýva, že Sentence-BERT bol mierne úspešnejší pri samotnom vyhľadaní relevantných článkov, zatiaľ čo TF-IDF mierne dominoval v kvalite ich zoradenia. Tento výsledok je v súlade s charakterom oboch modelov. Sentence-BERT vďaka sémantickým embeddingom lepšie zachytáva významovú podobnosť medzi článkami, a preto dokáže odporučiť relevantné dokumenty aj v prípadoch, keď sa nepoužívajú úplne rovnaké výrazy. TF-IDF naopak profituje z presnej zhody termínov a kľúčových slov, čo sa môže pozitívne prejavovať najmä pri presnejšom poradí už nájdených relevantných výsledkov.

Vplyv používateľských interakcií sa v tomto experimente prejavil tým, že kvalita odporúčaní bola priamo závislá od tematickej konzistentnosti označení *like*, z ktorých sa vytváral používateľský profil. Keďže profil vznikal výhradne z explicitných pozitívnych interakcií, výsledné odporúčania odrážali najmä obsahovú podobnosť k článkom, ktoré používateľ označil ako zaujímavé. Skupinové interakcie a spätná väzba vo forme odmietnutia odporúčaní v tomto základnom experimente zahrnuté neboli. Ich vplyv na kvalitu odporúčaní bol analyzovaný až v rozšírenom scenári uvedenom v nasledujúcej podkapitole.

Celkovo možno konštatovať, že oba modely dosiahli porovnateľné výsledky a oba boli schopné vytvárať použiteľné personalizované odporúčania. Sentence-BERT sa ukázal ako mierne vhodnejší model z pohľadu schopnosti zachytiť relevantné články používateľa, zatiaľ čo TF-IDF ostal konkurencieschopným riešením najmä v kvalite zoradenia odporúčaní. Výsledky základného experimentu tak potvrdili, že porovnanie oboch prístupov má v kontexte odporúčania vedeckých článkov zmysel a že každý z nich má odlišné silné stránky.

6.4.2 Rozšírený experiment personalizovaných odporúčaní

Druhý experiment bol navrhnutý ako rozšírený scenár funkcie *Recommended for you*, ktorého cieľom bolo overiť správanie oboch modelov v realistickejšom prostredí. Na rozdiel od základného experimentu sa používateľský profil nevytváral iba z explicitných označení *like*, ale aj z ďalších typov interakcií, ktoré zodpovedajú reálnemu používaniu systému. Do profilu preto vstupovali nielen používateľské lajky, ale aj skupinové lajky, pozitívna spätná väzba na odporúčané články a negatívna spätná väzba vo forme odmietnutia odporúčaní.

V experimente boli použité 3 používateľské profily, pri ktorých bol scenár pripravený podrobnejšie než v prvom experimente. Každý používateľ mal vytvorených 20 základných interakcií typu *like*, bol členom skupín, v ktorých sa nachádzali skupinové označenia článkov ako obľúbených, a zároveň mal priradenú pozitívnu aj negatívnu spätnú väzbu na odporúčané články. Konkrétne sa pri každom používateľovi uvažovalo s 5 interakciami typu *positive feedback* a 4 interakciami typu *dismiss*. Takto pripravený scenár lepšie simuloval situáciu, v ktorej odporúčací systém pracuje s bohatším a dynamickejším profilom používateľa.

Používateľský profil bol v tomto experimente vytváraný ako vážený priemer embeddingov článkov, ktoré vychádzali z jednotlivých typov interakcií. Explicitné používateľské lajky predstavovali hlavný základ profilu, skupinové lajky slúžili ako doplnkový signál vyplývajúci z členstva používateľa v skupinách, pozitívna spätná väzba zosilňovala preferované tematické smery a odmietnuté odporúčania naopak profil korigovali negatívnym smerom. Pri výpočte profilu sa v systéme používali váhy +1,0 pre používateľské lajky, +0,7 pre skupinové lajky, +1,2 pre pozitívnu spätnú väzbu a -1,0 pre odmietnuté odporúčania. Takto vytvorený profil bol následne porovnávaný s embeddingmi ostatných článkov pomocou kosínusovej podobnosti, pričom model vrátil zoradený zoznam odporúčaní.

Pri rozšírenom experimente bolo potrebné zohľadniť aj metodický aspekt spätnej väzby. Keďže modely TF-IDF a Sentence-BERT generovali odlišné zoznamy odporúčaných článkov, spätná väzba nemohla byť vytvorená spoločne pre oba modely. Z tohto dôvodu bol experiment realizovaný oddelene pre každý model. Najskôr bol celý scenár pripravený a vyhodnotený pre model TF-IDF, následne bol profil používateľa resetovaný do pôvodného stavu a rovnaký postup bol zopakovaný pre model Sentence-BERT. Takýto prístup zabezpečil, že pozitívna aj negatívna spätná väzba bola vždy viazaná na odporúčania konkrétneho modelu, a nebola ovplyvnená výstupom druhého prístupu.

Na vyhodnotenie kvality odporúčaní bola použitá rovnaká sada metrík ako v základnom experimente, teda Precision@5, Recall@5, MAP@5, nDCG@5, Precision@10, Recall@10, MAP@10 a nDCG@10. Z 20 základných používateľských lajkov bolo pre každého používateľa 16 interakcií použitých na vytvorenie tréningovej časti profilu a


zvyšné 4 tvorili testovaciu množinu relevantných článkov. Skupinové interakcie a spätná väzba zostávali súčasťou profilu, pretože práve ich vplyv bol v tomto experimente predmetom sledovania.

Výsledky pre hodnotu $K = 5$ sú uvedené v tabuľke 6.3. V rozšírenom scenári dosiahol model TF-IDF lepšie výsledky vo všetkých sledovaných metrikách. Konkrétne dosiahol $\text{Precision@5} = 0,4000$, $\text{Recall@5} = 0,5000$, $\text{MAP@5} = 0,4375$ a $\text{nDCG@5} = 0,5456$. Model Sentence-BERT dosiahol pri rovnakom nastavení $\text{Precision@5} = 0,2667$, $\text{Recall@5} = 0,3333$, $\text{MAP@5} = 0,1861$ a $\text{nDCG@5} = 0,3276$. Z týchto hodnôt vyplýva, že TF-IDF bol v tomto scenári úspešnejší nielen pri samotnom nájdení relevantných článkov, ale aj pri ich zoradení na vyššie pozície odporúčaného zoznamu.

Tabuľka 6.3: Porovnanie výsledkov modelov TF-IDF a Sentence-BERT v rozšírenom experimente pre $K = 5$

Model	Precision@5	Recall@5	MAP@5	nDCG@5
TF-IDF	0,4000	0,5000	0,4375	0,5456
SBERT	0,2667	0,3333	0,1861	0,3276

Grafické porovnanie výsledkov pre $K = 5$ je zobrazené na obrázku 6.4. Už pri najužšom zozname odporúčaní je viditeľné, že TF-IDF prekonal Sentence-BERT vo všetkých metrikách. Najvýraznejší rozdiel sa prejavil najmä v metrikách MAP@5 a nDCG@5 , čo naznačuje, že TF-IDF vedel relevantné články nielen nájsť, ale aj lepšie zoradiť medzi najvyššie odporúčania.




Obr. 6.4: Porovnanie výsledkov modelov TF-IDF a Sentence-BERT v rozšírenom experimente pre $K = 5$

Výsledky pre hodnotu $K = 10$ sú uvedené v tabuľke 6.4. Aj pri širšom zozname odporúčaní si model TF-IDF zachoval prevahu vo všetkých metrikách. Dosiahol hodnoty $\text{Precision@10} = 0,2667$, $\text{Recall@10} = 0,6667$, $\text{MAP@10} = 0,4891$ a $\text{nDCG@10} = 0,6281$. Sentence-BERT v tom istom scenári dosiahol $\text{Precision@10} = 0,2333$, $\text{Recall@10} = 0,5833$, $\text{MAP@10} = 0,2972$ a $\text{nDCG@10} = 0,4614$. Výsledky tak naznačujú, že pri rozšírenom profile používateľa bol TF-IDF úspešnejší aj pri širšom zozname odporúčaní.

Tabuľka 6.4: Porovnanie výsledkov modelov TF-IDF a Sentence-BERT v rozšírenom experimente pre $K = 10$

Model	Precision@10	Recall@10	MAP@10	nDCG@10
TF-IDF	0,2667	0,6667	0,4891	0,6281
SBERT	0,2333	0,5833	0,2972	0,4614


Grafické porovnanie výsledkov pre $K = 10$ je znázornené na obrázku 6.5. Z grafu je viditeľné, že rozdiel medzi modelmi sa zachoval aj pri širšom zozname odporúčaní. TF-IDF dosiahol lepšie výsledky v precision, recall aj v metrikách hodnotiacich poradie výsledkov, čím potvrdil stabilnejší výkon v rámci tohto rozšíreného scenára.



Obr. 6.5: Porovnanie výsledkov modelov TF-IDF a Sentence-BERT v rozšírenom experimente pre $K = 10$

Pre lepšiu interpretáciu rozdielov medzi modelmi je na obrázku 6.6 zobrazený aj graf rozdielov jednotlivých metrík. Kladné hodnoty v tomto prípade znamenajú lepší výsledok modelu Sentence-BERT a záporné hodnoty lepší výsledok modelu TF-IDF.

Všetky sledované metriky nadobúdajú záporné hodnoty, čo potvrdzuje, že v rozšírenom scenári bol úspešnejší model TF-IDF vo všetkých hodnotených ukazovateľoch.



Obr. 6.6: Rozdiely medzi výsledkami modelov Sentence-BERT a TF-IDF v rozšírenom experimente

Z pohľadu používateľských interakcií sa ukázalo, že rozšírenie profilu o pozitívnu a negatívnu spätnú väzbu malo citeľný vplyv na výsledné odporúčania. Pozitívna spätná väzba zosilňovala tematické oblasti, ktoré používateľ opakovane potvrdzoval ako relevantné, zatiaľ čo odmietnuté články pomáhali profil korigovať a potláčať menej vhodné smery odporúčania. V porovnaní so základným experimentom tak vznikol bohatší a presnejšie zameraný profil používateľa.

Významnú úlohu zohrali aj skupinové interakcie. Skupinové lajky predstavovali doplnkový signál, ktorý rozširoval profil používateľa o články tematicky blízke jeho individuálnym preferenciám. V tomto experimente tak profil neodrážal iba individuálne správanie používateľa, ale aj širší kontext jeho odborného zamerania v rámci skupinového prostredia. Práve kombinácia individuálnych lajkov, skupinových interakcií a spätnej väzby vytvorila realistickejší scenár, v ktorom bolo možné sledovať, ako si oba modely poradia s komplexnejším profilom.

Výsledky rozšíreného experimentu ukázali, že pri takto zostavených používateľských profiloch bol model TF-IDF úspešnejší než Sentence-BERT vo všetkých sledovaných metrikách. Tento výsledok naznačuje, že v situáciách, kde používateľský profil vzniká z tematicky úzko zameraných článkov a je ďalej spresňovaný opakovanými interakciami, môže byť klasická štatistická reprezentácia textu veľmi efektívna. Rozšírený experiment tak potvrdil, že pri personalizovanom odporúčaní vedeckých článkov môže mať TF-IDF aj naďalej veľmi silnú praktickú hodnotu.

6.5 Porovnanie výsledkov a interpretácia

Výsledky experimentálneho vyhodnotenia ukázali, že správanie modelov TF-IDF a Sentence-BERT sa menilo v závislosti od typu personalizačného scenára. V základnom experimente, v ktorom bol používateľský profil vytváraný iba na základe explicitných označení *like*, dosiahol Sentence-BERT mierne lepšie výsledky v metrikách Precision@5, Recall@5, Precision@10 a Recall@10. Naopak model TF-IDF dosiahol mierne lepšie hodnoty v metrikách MAP@5, nDCG@5, MAP@10 a nDCG@10. Z toho vyplýva, že v jednoduchšom scenári bol Sentence-BERT o niečo úspešnejší pri samotnom nájdení relevantných článkov, zatiaľ čo TF-IDF bol mierne lepší v ich zoradení na vyššie pozície odporúčaného zoznamu.

V rozšírenom experimente sa však situácia zmenila. Používateľský profil už nevznikal iba zo základných lajkov, ale aj zo skupinových interakcií, pozitívnej spätnej väzby a odmietnutých odporúčaní. V tomto realistickejšom scenári dosiahol model TF-IDF lepšie výsledky vo všetkých sledovaných metrikách. Oproti modelu Sentence-BERT bol úspešnejší nielen pri nájdení relevantných článkov, ale aj pri ich zoradení. Výsledky tak ukázali, že pri komplexnejšom profile používateľa sa výkonnosť oboch modelov môže meniť a že správanie modelov nemožno hodnotiť len na základe jedného typu experimentu.

Získané výsledky naznačujú, že TF-IDF dosahoval lepšie výsledky najmä v situáciách, keď bol používateľský profil tematicky úzko zameraný a vytváral sa z článkov s výrazným prekryvom odborných termínov a kľúčových slov. V rozšírenom experimente sa profil používateľa ďalej spresňoval opakovanými pozitívnymi interakciami a zároveň korigoval negatívnou spätnou väzbou. Takto vytvorený profil bol terminologicky veľmi konzistentný, čo vyhovovalo práve modelu TF-IDF. Keďže tento model pracuje so štatistickou reprezentáciou slov a ich váh v rámci korpusu, dokázal v technicky úzko vymedzených témach efektívne využiť presnú zhodu výrazov a vrátiť relevantné články s veľmi podobnou terminológiou.

Naopak Sentence-BERT sa ukázal ako výhodnejší v jednoduchšom scenári, v ktorom profil používateľa vznikol iba na základe základných interakcií typu *like*. V tomto prípade dosiahol mierne lepšie výsledky v precision a recall, čo naznačuje, že pri menšom množstve používateľských signálov dokázal lepšie zachytiť významovú podobnosť medzi článkami. Jeho výhodou je práve schopnosť pracovať so sémantickou reprezentáciou textu, a teda odporučiť tematicky blízke články aj v prípadoch, keď nepoužívajú úplne rovnaké výrazy alebo odborné termíny. Tento typ reprezentácie je výhodný najmä v situáciách, keď používateľský profil ešte nie je veľmi presne vyhranený alebo keď relevantnosť článkov nemožno posúdiť iba na základe presného prekryvu kľúčových slov.

Z pohľadu cieľov práce sú tieto výsledky dôležité z viacerých dôvodov. Potvrdili, že oba porovnávané modely sú schopné vytvárať použiteľné personalizované odporúča-

nia vedeckých článkov, no každý z nich je vhodnejší v odlišnom type scenára. Zároveň sa ukázalo, že modernejší sémantický model Sentence-BERT nemusí byť automaticky lepší vo všetkých situáciách. Hoci v jednoduchšom experimente dosiahol priaznivejšie výsledky pri identifikácii relevantných článkov, v rozšírenom scenári s bohatším a tematicky presnejším profilom používateľa sa ukázala sila klasického modelu TF-IDF.

Výsledky preto možno interpretovať tak, že kvalita odporúčaní nezávisí iba od samotného modelu reprezentácie textu, ale aj od povahy používateľského profilu a od typu dostupných interakcií. Ak je profil používateľa vytvorený z menšieho množstva signálov a obsahuje širšie sémantické presahy, môže byť výhodnejší Sentence-BERT. Ak sa však profil opiera o tematicky úzke a terminologicky konzistentné články, navyše doplnené o spätnú väzbu a skupinové interakcie, môže byť veľmi efektívny aj model TF-IDF. Práve táto závislosť od scenára predstavuje jeden z hlavných prínosov experimentálneho vyhodnotenia, pretože ukazuje, že pri návrhu odporúčacieho systému pre vedecké články je potrebné brať do úvahy nielen typ modelu, ale aj charakter dát a správanie používateľov.

6.6 Zhrnutie experimentálnej časti

Experimentálna časť tejto diplomovej práce bola zameraná na vyhodnotenie funkcie *Recommended for you* a na porovnanie dvoch prístupov k reprezentácii obsahu vedeckých článkov, konkrétne metódy TF-IDF a modelu Sentence-BERT. Vyhodnotenie bolo realizované v dvoch nadväzujúcich scenároch. Prvý predstavoval základný experiment, v ktorom bol používateľský profil vytváraný iba na základe explicitných označení *like*. Druhý predstavoval rozšírený experiment, v ktorom bol profil používateľa doplnený aj o skupinové interakcie, pozitívnu spätnú väzbu a odmietnuté odporúčania. Takto navrhnutý postup umožnil sledovať správanie oboch modelov v jednoduchšom aj realistickejšom personalizačnom prostredí.

Hlavné zistenia experimentálneho vyhodnotenia ukázali, že oba modely sú schopné vytvárať použiteľné personalizované odporúčania vedeckých článkov, avšak ich správanie sa mení v závislosti od charakteru používateľského profilu a od typu dostupných interakcií. V základnom experimente dosiahol Sentence-BERT mierne lepšie výsledky v metrikách *precision* a *recall*, čo naznačilo, že pri jednoduchšom profile používateľa dokáže účinnejšie identifikovať relevantné články na základe významovej podobnosti. Model TF-IDF naopak dosiahol mierne lepšie výsledky v metrikách *MAP* a *nDCG*, teda v kvalite zoradenia relevantných odporúčaní.

V rozšírenom experimente sa ukázal odlišný trend. Pri bohatšom profile používateľa, ktorý vznikol kombináciou individuálnych lajkov, skupinových interakcií, pozitívnej spätnej väzby a odmietnutých odporúčaní, dosiahol lepšie výsledky model TF-IDF

vo všetkých sledovaných metrikách. Tento výsledok naznačuje, že pri tematicky úzko zameraných používateľských profiloch a pri výraznom opakovaní odborných termínov môže byť klasická štatistická reprezentácia textu veľmi efektívna a v konkrétnych situáciách môže prekonať aj modernejší sémantický model.

Na základe týchto výsledkov možno odpovedať na výskumnú otázku práce nasledovne: ani jeden z porovnávaných modelov nemožno označiť za jednoznačne najlepší vo všetkých situáciách. Sentence-BERT sa ukázal ako mierne výhodnejší v jednoduchšom scenári, kde používateľský profil vznikol len z obmedzeného množstva základných interakcií a kde bola dôležitá schopnosť zachytiť významovú podobnosť medzi článkami. TF-IDF sa naopak ukázal ako výhodnejší v realistickejšom rozšírenom scenári, kde profil používateľa vznikol z tematicky konzistentných interakcií a bol ďalej spresňovaný skupinovými signálmi a spätnou väzbou. Experimentálne vyhodnotenie teda potvrdilo, že kvalita personalizovaného odporúčania vedeckých článkov závisí nielen od zvoleného modelu reprezentácie textu, ale aj od charakteru dát, miery tematickej konzistentnosti profilu a od typu interakcií, z ktorých sa tento profil vytvára.

Kapitola 7

Diskusia a zhodnotenie

Záver

Literatúra

- [1] Christine L. Borgman. *Scholarship in the Digital Age: Information, Infrastructure, and the Internet*. MIT Press, Cambridge, MA, 2007.
- [2] Lutz Bornmann and Rüdiger Mutz. Growth rates of modern science: A bibliometric analysis based on the number of publications and cited references. *Journal of the Association for Information Science and Technology*, 66(11):2215–2222, 2015. Navštívené: 2026-03-18.
- [3] Jöran Beel, Bela Gipp, and Erik Wilde. Academic search engine optimization (aseo): Optimizing scholarly literature for google scholar & co. *Journal of Scholarly Publishing*, 41(2):176–190, 2010. Navštívené: 2026-03-18.
- [4] Jöran Beel and Bela Gipp. Google scholar’s ranking algorithm: An introductory overview. In *Proceedings of the 12th International Conference on Scientometrics and Informetrics (ISSI’09)*, pages 230–241, Rio de Janeiro, Brazil, 2009. International Society for Scientometrics and Informetrics. Navštívené: 2026-03-18.
- [5] Patrice Pottier, Enrico Ser-Giacomi, and Franck Courchamp. Title, abstract and keywords: a practical guide to maximize the visibility and impact of academic papers. *Proceedings of the Royal Society B: Biological Sciences*, 291(2031):20241222, 2024. Navštívené: 2026-03-18.
- [6] Waleed Ammar, Dirk Groeneveld, Chandra Bhagavatula, Iz Beltagy, Miles Crawford, Doug Downey, Jason Dunkelberger, Ahmed Elgohary, Sergey Feldman, Vu Ha, Rodney Kinney, Sebastian Kohlmeier, Kyle Lo, Tyler Murray, Hsu-Han Ooi, Matthew Peters, Joanna Power, Sam Skjonsberg, Lucy Lu Wang, Chris Wilhelm, Zheng Yuan, Madeleine van Zuylen, and Oren Etzioni. Construction of the literature graph in semantic scholar. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 3 (Industry Papers)*, pages 84–91, New Orleans, Louisiana, 2018. Association for Computational Linguistics. Navštívené: 2026-03-18.

- [7] Weijuan Li. Scientific paper recommender system using deep learning and link prediction in citation network. *Heliyon*, 10(14):e34685, 2024. Navštívené: 2026-03-18.
- [8] MDN Web Docs. Client-server overview. https://developer.mozilla.org/en-US/docs/Learn/Server-side/First_steps/Client-Server_overview, 2025. Navštívené: 2026-04-12.
- [9] Mark Richards and Neal Ford. *Fundamentals of Software Architecture: An Engineering Approach*. O'Reilly Media, Sebastopol, 2020.
- [10] Len Bass, Paul Clements, and Rick Kazman. *Software Architecture in Practice*. Addison-Wesley, Boston, 4 edition, 2021.
- [11] IBM. What is a database? <https://www.ibm.com/think/topics/database>, 2025. Navštívené: 2026-04-12.
- [12] IBM. What is data modeling? <https://www.ibm.com/think/topics/data-modeling>, 2025. Navštívené: 2026-04-12.
- [13] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, Cambridge, 2008.
- [14] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988. Navštívené: 2026-04-12.
- [15] Nils Reimers and Iryna Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992. Association for Computational Linguistics, 2019. Navštívené: 2026-04-12.
- [16] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2019. Navštívené: 2026-04-12.
- [17] Michael J. Pazzani and Daniel Billsus. Content-based recommendation systems. In Peter Brusilovsky, Alfred Kobsa, and Wolfgang Nejdl, editors, *The Adaptive Web*, pages 325–341. Springer, Berlin, Heidelberg, 2007. Navštívené: 2026-04-12.
- [18] Pasquale Lops, Marco de Gemmis, and Giovanni Semeraro. Content-based recommender systems: State of the art and trends. In Francesco Ricci, Lior Rokach, Bracha Shapira, and Paul B. Kantor, editors, *Recommender Systems Handbook*, pages 73–105. Springer, Boston, MA, 2011. Navštívené: 2026-04-12.

- [19] Jung-Ran Park. Metadata quality in digital repositories: A survey of the current state of the art. *Cataloging & Classification Quarterly*, 47(3–4):213–228, 2009. Navštívené: 2026-04-12.
- [20] Ginny Hendricks, Dominika Tkaczyk, Jennifer Lin, and Patricia Feeney. Crossref: The sustainable source of community-owned scholarly metadata. *Quantitative Science Studies*, 1(1):414–427, 2020. Navštívené: 2026-04-12.

Príloha A: